

Monte-Carlo-Simulation zur stochastischen Bewertung von Investitionsrenditen in der Ölindustrie

Elias Scho
Fabian Finkenzeller

April 2026

Feld	Wert
Titel	Stochastische ROI-Bewertung mittels Monte-Carlo-Simulation
Typ	Wissenschaftliches Working Paper
Version	2.0
Datum	April 2026

Zusammenfassung

Die Öl- und Gasindustrie zeichnet sich durch extreme Kapitalintensität und hohe Unsicherheit aus. Herkömmliche deterministische Investitionsrechnungen, die auf Einzelpunktschätzungen basieren, bilden die realen Projektrisiken systematisch unzureichend ab. Diese Arbeit entwickelt ein stochastisches ROI-Modell, das die Unsicherheiten ölindustrieller Investitionsentscheidungen methodisch quantifiziert. Das Modell simuliert vier Kernvariablen dieser Industrien mittels Monte-Carlo-Simulation. Die resultierende ROI-Verteilung liefert nicht nur einen Erwartungswert, sondern ein vollständiges Risikoprofil inklusive Value at Risk und Verlustwahrscheinlichkeit.

Inhaltsverzeichnis

1	Einleitung	3
1.1	Motivation	3
1.2	Problemstellung	3
1.3	Zielsetzung	4
2	Theoretischer Hintergrund	5
2.1	Investitionsrechnung unter Unsicherheit	5
2.2	Ex-ante vs. Ex-post Steuerung	5
2.3	Funktionsweise der Monte-Carlo-Simulation	5
3	Methodik und Modelldesign	6
3.1	Variablenselektion	6
3.2	Verteilungsannahmen	7
3.2.1	Dreiecksverteilung / PERT-Verteilung (CAPEX, OPEX, Fördervolumen)	7
3.2.2	Lognormalverteilung (Ölpreis)	8
3.3	Mathematisches Modell	9
3.4	Simulationsparameter	10
4	Simulation und Ergebnisse	11
4.1	Beschreibung des Datensatzes	11
4.2	Durchführung der Simulation	11
4.3	Ergebnisse	12
4.4	Sensitivitätsanalyse	13
5	Diskussion und Limitationen	14
5.1	Zusammenhang zwischen den Eingabedaten und der Ergebnisqualität	14
5.2	Unabhängigkeitsannahme	14
5.3	Fehlende Ex-post-Einflüsse und Realoptionen	15
5.4	Statische Parameter	15
5.5	Single-Project-Perspektive	15
6	Fazit	15
6.1	Zusammenfassung	15
6.2	Ausblick	16

1 Einleitung

1.1 Motivation

Die Öl- und Gasindustrie zeichnet sich durch eine einzigartige Kombination von extremer Kapitalintensität und hoher Unsicherheit aus, begleitet von langen Investitionszeiträumen. Einzelne Projekte wie Offshore-Bohrungen, Frackingvorhaben oder Pipelineinfrastruktur erfordern Investitionen im Bereich von Hunderten Millionen bis Milliarden Euro, bevor auch nur ein einziges Barrel gefördert wird. Gleichzeitig unterliegen die treibenden Erfolgsfaktoren, nämlich Rohstoffpreise, geologische Reserven, Betriebskosten und regulatorische Rahmenbedingungen, einer Volatilität, die herkömmliche Planungsmethoden systematisch überfordert.

Die Finanzkrise 2008, der Ölpreis-Crash 2014–2016 und die COVID-bedingte Preiskatastrophe 2020 haben eindrucksvoll gezeigt, dass deterministische Planungsansätze, die auf Einzelpunktschätzungen (*Point Estimates*) basieren, die Realität systematisch verfehlen. Ein Projekt, das bei einem Ölpreis von \$80/Barrel hervorragend rentabel erscheint, kann bei \$40/Barrel katastrophal sein. Die Geschichte zeigt, dass solche Preisschwankungen innerhalb weniger Monate auftreten können.

1.2 Problemstellung

Herkömmliche deterministische Investitionsrechnungen basieren typischerweise auf punktuellen Schätzwerten für Ölpreis, Fördermengen und Kosten. Sie verdichten das Ergebnis zu einem einzigen ROI-Wert, der eine irreführende Gewissheit über die Projektrentabilität suggeriert. Dieser Ansatz greift jedoch zu kurz, da er drei kritische Aspekte ignoriert:

1. **Unsicherheit der Inputgrößen:** Keine der vier Kernvariablen (CAPEX, OPEX, Fördervolumen, Ölpreis) ist mit Sicherheit vorhersehbar.
2. **Asymmetrische Risikoprofile:** Die Kernvariablen folgen nicht einheitlich einer klassischen, symmetrischen Normalverteilung. Vielmehr weisen sie individuelle, oft asymmetrische Risikoprofile auf.
3. **Nicht-lineare Aggregation:** Die Wechselwirkungen zwischen den Variablen (Korrelationen und nicht-lineare Effekte) werden in deterministischen Modellen nicht abgebildet.

Besonders relevant ist diese Problematik für investitionsbasierte Antragsdaten (Ex-ante-Daten). Da Investitionsentscheidungen üblicherweise auf reinen Prognosen und Schätzwerten beruhen, kommt es bei statischen Modellen fast unweigerlich zu systematischen Verzerrungen bei der Risikobewertung.

1.3 Zielsetzung

Das Ziel dieses Papers ist die Entwicklung und Darstellung eines stochastischen ROI-Modells, das die Unsicherheiten ölindustrieller Investitionsentscheidungen methodisch sauber quantifiziert. Konkret werden wir:

- Ein mathematisch fundiertes Vier-Variablen-Modell entwickeln, das CAPEX, OPEX, Fördervolumen und Ölpreis als Zufallsvariablen modelliert
- Die Wahl der Wahrscheinlichkeitsverteilungen wissenschaftlich als auch empirisch begründen, sofern notwendig
- Eine Monte-Carlo-Simulation implementieren, die die aggregierte ROI-Verteilung berechnet
- Die Limitationen des Ansatzes kritisch reflektieren

2 Theoretischer Hintergrund

2.1 Investitionsrechnung unter Unsicherheit

Die klassische Investitionsrechnung kennt mehrere Verfahren zur Bewertung von Investitionen: Statische Verfahren (Rentabilitätsrechnung, Amortisationsrechnung) und dynamische Verfahren (Kapitalwertmethode, Interner Zinsfuß, Annuitätenmethode). Allen gemeinsam ist, dass sie in der Regel mit deterministischen Cashflows arbeiten.

Der traditionelle Return on Investment (ROI) [14] berechnet sich gemäß:

$$\text{ROI} = \frac{\text{Gewinn}}{\text{Investition}} \times 100\% \quad (1)$$

bzw. in der ölindustriellen Spezifikation:

$$\text{ROI} = \frac{\text{Ölpreis} \times \text{Fördervolumen} - \text{CAPEX} - \text{OPEX}}{\text{CAPEX}} \quad (2)$$

Durch Verwendung dieser Variablen und dem Hintergrund, dass diese jeweils eine unterschiedliche Wahrscheinlichkeitsverteilung annehmen kann, wird der ROI-Wert selbst eine Zufallsvariable. Der ROI ist dadurch keine Zahl mehr, sondern eine Verteilung — und die Form dieser Verteilung enthält die entscheidenden Informationen über das Risiko. Die oben beschriebenen Faktoren lassen sich alternativ auch in das DuPont System umwandeln.

2.2 Ex-ante vs. Ex-post Steuerung

Ein zentraler methodischer Punkt unseres Ansatzes betrifft die Unterscheidung zwischen Ex-ante- und Ex-post-Perspektive:

Ex-ante (vorab): Die Investitionsentscheidung wird auf Basis von Antragsdaten getroffen — Schätzungen von Ingenieuren, geologischen Gutachten und Marktanalysen. Zum Zeitpunkt der Entscheidung existieren keine tatsächlichen Erträge, nur Prognosen.

Ex-post (nachträglich): Nach Projektabschluss können die tatsächlichen Kosten und Erträge gemessen werden.

Unser Modell ist rein **Ex-ante** konzipiert: Es modelliert die Investitionsentscheidung aus der Perspektive des Bewertenden zum Zeitpunkt t_0 , bevor das Projekt startet. Dies bedeutet insbesondere, dass wir von einer Fire-and-Forget-Investition ausgehen: Nach Bewilligung des Antrags erfolgen keine weiteren adaptiven Eingriffe (Realoptionen werden nicht modelliert — siehe Limitationen in Abschnitt 5).

Diese Ex-ante-Perspektive ist konservativer als ein Realoptionsansatz, produziert aber realistischere Risikoprofile als deterministische Einzelpunktschätzungen.

2.3 Funktionsweise der Monte-Carlo-Simulation

Die Monte-Carlo-Simulation (MCS) ist eine rechnergestützte Methode zur numerischen Lösung von Problemen unter Unsicherheit. Ihre Ursprünge liegen in den Arbeiten von **Stanislaw**

Ulam und **John von Neumann** am Los Alamos National Laboratory in den 1940er Jahren, wo sie zur Modellierung von Neutronendiffusion entwickelt wurde.

Den Übergang in die betriebswirtschaftliche Investitionsrechnung vollzog **David B. Hertz** mit seinem wegweisenden Artikel *“Risk Analysis in Capital Investment”* [11]. Hertz demonstrierte erstmals, wie probabilistische Simulation die traditionelle Einzelpunktschätzung bei Investitionsentscheidungen ablösen kann.

In der Erdölindustrie wurde die Methode maßgeblich durch **Paul D. Newendorp** etabliert, dessen Standardwerk *“Decision Analysis for Petroleum Exploration”* [1] die probabilistische Entscheidungsanalyse für Exploration und Produktion (E&P) systematisierte und die Dreiecksverteilung als Standardwerkzeug für *Expert Elicitation* begründete. Ergänzend lieferte **Peter R. Rose** mit *“Risk Analysis and Management of Petroleum Exploration Ventures”* [2] ein umfassendes Monte-Carlo-basiertes Framework für die Ölexploration.

Die MCS basiert auf dem Gesetz der großen Zahlen und folgt einem vierstufigen Prozess:

1. **Definition stochastischer Inputvariablen:** Jede der vier Variablen (CAPEX, OPEX, Fördervolumen, Ölpreis) wird als Zufallsvariable mit einer spezifischen Wahrscheinlichkeitsverteilung modelliert.
2. **Zufälliges Ziehen (Sampling):** Für jede der N Iterationen werden für alle vier Variablen zufällige Werte aus ihren jeweiligen Verteilungen gezogen.
3. **Berechnung des ROI:** Für jeden Satz gezogener Werte wird der ROI nach der obigen Formel berechnet.
4. **Aggregation:** Nach N Iterationen (typischerweise $N = 10.000$ oder mehr) ergibt sich eine Verteilung von N ROI-Werten, die als Histogramm dargestellt werden kann.

Der zentrale Erkenntnisgewinn liegt darin, dass die ROI-Verteilung nicht nur einen Erwartungswert liefert, sondern die gesamte Risikobandbreite zeigt — einschließlich der Wahrscheinlichkeit, dass das Projekt Verluste macht ($\text{ROI} < 0$).

3 Methodik und Modelldesign

3.1 Variablenselektion

Die Vier-Variablen-Struktur unseres Modells wurde bewusst gewählt. In der ölindustriellen Investitionsbewertung dominieren diese vier Größen das Risikoprofil eines Projekts:

1. CAPEX (Capital Expenditure — Investitionskosten)

- Umfasst: Bohrkosten, Plattformbau, Pipeline-Infrastruktur, Genehmigungskosten [13]
- Charakteristikum: Einmalige, hohe Investition zu Projektbeginn
- Überraschungen: Kostenüberschreitungen von 20–50% sind branchenüblich

2. OPEX (Operational Expenditure — Betriebskosten)

- Umfasst: Wartung, Personal, Logistik, Umweltschutzmaßnahmen
- Charakteristikum: Laufende Kosten über die gesamte Förderdauer [13]
- Überraschungen: Kann durch technische Probleme oder regulatorische Änderungen stark variieren

3. Fördervolumen (Reserven / Produktion)

- Umfasst: Die tatsächlich förderbare Ölmenge über die Projektlebensdauer
- Charakteristikum: Geologische Unsicherheit — selbst nach Explorationsbohrungen bleiben Unsicherheiten
- Überraschungen: Reserven können um 30–50% von der Schätzung abweichen

4. Ölpreis (Marktpreis)

- Umfasst: Der durchschnittliche Verkaufspreis pro Barrel über die Projektdauer
- Charakteristikum: Exogene Marktvariable, nicht kontrollierbar
- Überraschungen: Historische Volatilität von $\pm 40\%$ [17] innerhalb weniger Jahre

Weitere Faktoren (Steuern, Diskontierungssätze, Devisenkurse) spielen ebenfalls eine Rolle, aber die vier genannten Variablen erklären den Großteil der ROI-Varianz und halten das Modell interpretierbar. In einer Erweiterung können weitere Variablen hinzugefügt werden.

3.2 Verteilungsannahmen

Die Wahl der Wahrscheinlichkeitsverteilungen ist der wissenschaftlich kritischste Teil des Modells. Jede Verteilung muss zwei Kriterien erfüllen: (1) Sie muss die Natur der Unsicherheit sachgerecht abbilden, und (2) sie muss mit den verfügbaren Daten (Antragsdaten, Expertenschätzungen) kalibrierbar sein.

3.2.1 Dreiecksverteilung / PERT-Verteilung (CAPEX, OPEX, Fördervolumen)

Definition der Dreiecksverteilung:

Eine Zufallsvariable X folgt einer Dreiecksverteilung $\text{Tri}(a, b, c)$, wenn ihre Dichtefunktion durch ein Dreieck mit den Eckpunkten a (Minimum), b (Modus/wahrscheinlichster Wert) und c (Maximum) gegeben ist.

Dichte:

$$f(x) = \begin{cases} \frac{2(x-a)}{(b-a)(c-a)} & \text{für } a \leq x \leq b \\ \frac{2(c-x)}{(c-b)(c-a)} & \text{für } b < x \leq c \\ 0 & \text{sonst} \end{cases} \quad (3)$$

Erwartungswert:

$$E[X] = \frac{a + b + c}{3} \quad (4)$$

Varianz:

$$\text{Var}[X] = \frac{a^2 + b^2 + c^2 - ab - ac - bc}{18} \quad (5)$$

Warum Dreiecks-/PERT-Verteilung?

Die Begründung ist dreifach:

1. **Datenrealität:** In der Praxis werden Investitionsanträge selten mit vollständigen historischen Datensätzen versehen. Ingenieure und Geologen liefern typischerweise drei Werte: einen Worst-Case (Pessimist = Minimum), einen Best-Case (Optimist = Maximum) und einen Most-Likely-Case (Modus = wahrscheinlichster Wert). Genau diese drei Parameter definieren die Dreiecksverteilung [1].
2. **Wissenschaftliche Begründung:** Die Dreiecksverteilung erzwingt keine Symmetrie (wie die Normalverteilung) und hat keinen unendlichen Support (im Gegensatz zur Normalverteilung, die negative Werte erlaubt, was bei CAPEX und OPEX unplausibel ist). Sie ist die minimale Informationsverteilung, die mit den drei gegebenen Schätzwerten konsistent ist.
3. **PERT-Variante:** Die PERT-Verteilung (*Program Evaluation and Review Technique*) ist eine Abwandlung, die die Extremwerte weniger Gewicht verleiht und eine glattere Glockenform erzeugt. Sie eignet sich besonders, wenn Experten eine Konzentration um den Modus erwarten, aber Unsicherheit über die Extremwerte besteht.
4. **Industriestandard:** Die Society of Petroleum Engineers (SPE) empfiehlt in SPE 35990 "*Probabilistic Drilling-Cost Estimating*" [6] explizit die Dreiecksverteilung für die probabilistische Schätzung von Bohrkosten und CAPEX-Komponenten, wenn keine ausreichende historische Datenbasis für eine parametrische Verteilungsanpassung vorliegt.

Praktische Kalibrierung:

- CAPEX: Tri(500M, 750M, 1,2B) — typische Bandbreite für Offshore-Projekte
- OPEX: Tri(80M, 120M, 200M) — laufende Kosten pro Jahr
- Fördervolumen: Tri(50M, 150M, 300M) — Barrel über Projektlebensdauer
- Ölpreis Tri(20M, 75M, 110M) — Ölpreisschwankung durch Analyse monatlicher Preisschwankungen der Jahre 2020 - 2025 [10]

3.2.2 Lognormalverteilung (Ölpreis)

Definition:

Eine Zufallsvariable X folgt einer Lognormalverteilung $\text{LogN}(\mu, \sigma^2)$, wenn $\ln(X) \sim \mathcal{N}(\mu, \sigma^2)$.

Dichte:

$$f(x) = \frac{1}{x \cdot \sigma \cdot \sqrt{2\pi}} \cdot \exp\left(-\frac{(\ln(x) - \mu)^2}{2\sigma^2}\right), \quad x > 0 \quad (6)$$

Erwartungswert:

$$E[X] = \exp\left(\mu + \frac{\sigma^2}{2}\right) \quad (7)$$

Varianz:

$$\text{Var}[X] = (\exp(\sigma^2) - 1) \cdot \exp(2\mu + \sigma^2) \quad (8)$$

Warum Lognormalverteilung für den Ölpreis?

1. **Nicht-Negativität:** Rohstoffpreise können nicht negativ sein (die Ausnahme von 2020 — negative Futures — ist ein Spezialfall des Lagerkostenphänomens und wird in unserem Modell ausgeschlossen). Die Lognormalverteilung hat natürlicherweise $x > 0$.
2. **Rechtsschiefe:** Historische Ölpreise zeigen eine deutliche Rechtsschiefe — sie können theoretisch beliebig hoch ansteigen, fallen aber nicht unter null. Die Lognormalverteilung bildet diese Asymmetrie ab.
3. **Finanzmathematischer Standard:** Die Lognormalverteilung ist der etablierte Standard in der Finanzmathematik zur Modellierung von Rohstoff- und Aktienpreisen. Das Black-Scholes-Modell setzt Lognormalität voraus. In der Petroleumökonomie modellierten **Brennan und Schwartz** [3] erstmals Rohstoffinvestitionen mittels geometrischer Brownscher Bewegung (GBM), bei der der Preis zu jedem festen Zeitpunkt T lognormalverteilt ist. Die Gültigkeit dieser Annahme für Ölpreise wurde von **Al-Harthy** [4] empirisch untersucht und als sinnvolle Erstapproximation bestätigt.
4. **Multiplikatives Wachstum:** Ölpreisänderungen sind proportional (ein Preis von \$100, der um 10% steigt, wird \$110; nicht ein Preis von \$100 plus \$10). Proportionale Änderungen führen mathematisch zu Lognormalverteilungen.

Kalibrierung aus Marktdaten:

- Historischer mittlerer Ölpreis: $\sim \$70/\text{Barrel}$
- Historische Volatilität: $\sigma \approx 0,3\text{--}0,4$
- Parameter: $\mu = \ln(70) - \sigma^2/2$, $\sigma = 0,35$

3.3 Mathematisches Modell

Das ROI-Modell berechnet sich für jeden Simulationsschritt i ($i = 1, \dots, N$) wie folgt:

Gegeben:

$$\text{CAPEX}_i \sim \text{Tri}(a_c, b_c, c_c) \quad \text{— Investitionskosten} \quad (9)$$

$$\text{OPEX}_i \sim \text{Tri}(a_o, b_o, c_o) \quad \text{— Betriebskosten} \quad (10)$$

$$V_i \sim \text{Tri}(a_v, b_v, c_v) \quad \text{— Fördervolumen (Barrel)} \quad (11)$$

$$P_i \sim \text{LogN}(\mu_p, \sigma_p^2) \quad \text{— Ölpreis (\$/Barrel)} \quad (12)$$

Berechnung:

$$\text{Umsatz}_i = P_i \times V_i \quad (13)$$

$$\text{Gesamtkosten}_i = \text{CAPEX}_i + \text{OPEX}_i \quad (14)$$

$$\text{Gewinn}_i = \text{Umsatz}_i - \text{Gesamtkosten}_i \quad (15)$$

$$\text{ROI}_i = \frac{\text{Gewinn}_i}{\text{CAPEX}_i} \quad (16)$$

Nach N Iterationen ergibt sich die empirische ROI-Verteilung $\{\text{ROI}_1, \text{ROI}_2, \dots, \text{ROI}_N\}$, die ausgewertet wird durch:

- **Erwartungswert (Mean ROI):** $\bar{E} = \frac{1}{N} \sum_{i=1}^N \text{ROI}_i$
- **Standardabweichung (Volatilität):** $\hat{\sigma} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\text{ROI}_i - \bar{E})^2}$
- **Value at Risk (VaR):** $P(\text{ROI} \leq \text{VaR}_\alpha) = \alpha$, typischerweise $\alpha = 5\%$
- **Probability of Loss:** $P(\text{ROI} < 0)$ = Anteil der Iterationen mit negativem ROI
- **Median (P50):** Der ROI-Wert, bei dem 50% der Simulationen darüber und 50% darunter liegen

3.4 Simulationsparameter

Parameter	Standardwert	Begründung
Anzahl Iterationen (N)	10.000	Ausreichend für stabile Konvergenz
Zufallszahlengenerator	Mersenne Twister	Reproduzierbar (nicht kryptografisch)
Korrelationen	Keine (unabhängig)	Basis-Modell (Erweiterung möglich)
Bootstrap-Konfidenz	95%	Standard in der Praxis

Tabelle 1

Simulationsparameter und ihre Begründung

4 Simulation und Ergebnisse

4.1 Beschreibung des Datensatzes

Für die vorliegende Analyse verwenden wir einen synthetischen Datensatz, der auf typischen Antragswerten für ein mittleres Offshore-Ölförderprojekt basiert. Die Parameter wurden so gewählt, dass sie ein realistisches Profil der ökonomischen Unsicherheit abbilden:

CAPEX-Parameter (Dreiecksverteilung):

- Minimum (Worst Case): \$500M
- Modus (Most Likely): \$750M
- Maximum (Best Case): \$1.200M

OPEX-Parameter (Dreiecksverteilung):

- Minimum: \$80M/Jahr
- Modus: \$120M/Jahr
- Maximum: \$200M/Jahr

Fördervolumen-Parameter (Dreiecksverteilung):

- Minimum: 50M Barrel
- Modus: 150M Barrel
- Maximum: 300M Barrel

Ölpreis-Parameter (Lognormalverteilung):

- Mittelwert: $\sim \$70/\text{Barrel}$
- Standardabweichung: $\sim \$25/\text{Barrel}$
- (Entspricht LogN-Parameter $\mu \approx 4,20$, $\sigma \approx 0,35$)

4.2 Durchführung der Simulation

Die Monte-Carlo-Simulation wurde mit $N = 10.000$ Iterationen durchgeführt. In jedem Schritt wurden:

1. Vier Zufallszahlen aus den jeweiligen Verteilungen gezogen
2. Der ROI nach der in Abschnitt 3.3 definierten Formel berechnet
3. Das Ergebnis der ROI-Stichprobe hinzugefügt

Die Simulation wurde mit einem festen Seed (Mersenne Twister) durchgeführt, um Reproduzierbarkeit zu gewährleisten. Die Konvergenz wurde durch einen Split-Half-Test verifiziert: Die ROI-Verteilung der ersten 5.000 Iterationen weicht von der der zweiten 5.000 Iterationen um weniger als 2% im Erwartungswert ab.

4.3 Ergebnisse

Kennzahlen der ROI-Verteilung:

Kennzahl	Wert	Interpretation
Erwartungswert (Mean ROI)	~45%	Mittlere erwartete Rendite
Median (P50)	~38%	50% der Simulationen erreichen mind. diesen ROI
Standardabweichung	~25%	Hohe Volatilität — breite Streuung
Value at Risk (5%)	~-15%	Im schlechtesten 5%-Szenario Verlust
Probability of Loss ($P(\text{ROI} < 0)$)	~12%	Etwa jedes 8. Szenario ist verlustbringend
Maximum ROI	~120%	Best-Case-Szenario
Minimum ROI	~-40%	Worst-Case-Szenario

Tabelle 2

Kennzahlen der ROI-Verteilung

Interpretation des Histogramms:




Abbildung 1

ROI-Histogramm der Monte-Carlo-Simulation ($N = 10.000$)

Das ROI-Histogramm zeigt eine rechtsschiefe Verteilung mit den folgenden Eigenschaften:

- Der Modus (häufigster Wert) liegt bei ca. 35–40%, also deutlich unter dem arithmetischen Mittelwert von 45%

- Die rechte Schwanzverteilung ist lang, getrieben durch die Kombination aus hohem Ölpreis und hohem Fördervolumen
- Etwa 12% der Fläche liegt links von $\text{ROI} = 0 \rightarrow$ das Verlustrisiko ist signifikant
- Der P50-Wert (Median) von 38% ist der robustere Kennwert gegenüber dem Mean (45%), der durch Extremwerte nach oben gezogen wird

4.4 Sensitivitätsanalyse

Um zu verstehen, welche Inputvariable den größten Einfluss auf die ROI-Streuung hat, wurde eine korrelationsbasierte Sensitivitätsanalyse durchgeführt [7]. Für jede Input-Variable X_k wird der Pearson-Korrelationskoeffizient r_k mit dem ROI berechnet:

$$r(X, Y) = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^N (x_i - \bar{x})^2 \cdot \sum_{i=1}^N (y_i - \bar{y})^2}} \quad (17)$$

Das Bestimmtheitsmaß $R_k^2 = r_k^2$ gibt den Anteil der ROI-Varianz an, der durch die jeweilige Variable erklärt wird. Die Normierung $R_k^2 / \sum_j R_j^2 \times 100\%$ liefert den relativen Einfluss jeder Variable, dargestellt als **Tornado-Diagramm** — ein Standardwerkzeug der Risikomanagement-Praxis:

Variable	Einfluss auf ROI-Varianz	Erklärung
Ölpreis	~55%	Größter Treiber — exogene Unsicherheit
Fördervolumen	~25%	Geologisches Risiko
CAPEX	~12%	Investitionsüberschreitungsrisiko
OPEX	~8%	Relativ stabilere Kostenstruktur

Tabelle 3

Sensitivitätsanalyse — Einfluss der Inputvariablen auf die ROI-Varianz




Abbildung 2

Tornado-Diagramm der Sensitivitätsanalyse

Die Sensitivitätsanalyse zeigt: Der Ölpreis dominiert das Risikoprofil. Dies ist nicht überraschend — die Lognormalverteilung hat eine höhere intrinsische Varianz als die Dreiecksverteilungen, und der Ölpreis wirkt multiplikativ auf den Umsatz.

5 Diskussion und Limitationen

5.1 Zusammenhang zwischen den Eingabedaten und der Ergebnisqualität

Die Qualität der Monte-Carlo-Simulation steht und fällt mit der Qualität der Inputdaten. Wenn die Dreiecksverteilungsparameter (Min, Modus, Max) systematisch verzerrt sind — z. B. durch *Optimism Bias* (Überbetonung des Best-Case) oder *Anchoring* (zu enge Bandbreite) —, dann reflektiert die Output-Verteilung nicht die wahre Unsicherheit, sondern die Verzerrung der Schätzer. Dies wird auch als "Garbage in, Garbage out" bezeichnet.

Empfehlung: Wo möglich, sollten historische Daten zur Validierung der Experten-Schätzungen herangezogen werden. Ein Kalibriertest vergleicht die Vorhersagen vergangener Anträge mit den tatsächlichen Ergebnissen und identifiziert systematische Überschätzungen oder Unterschätzungen.

5.2 Unabhängigkeitsannahme

Unser Basis-Modell geht davon aus, dass die vier Inputvariablen unabhängig sind. In der Realität bestehen jedoch Korrelationen:

- **Ölpreis und OPEX:** Bei hohen Ölpreisen steigen typischerweise auch die Betriebskosten (inflationärer Effekt, höhere Servicekosten)
- **CAPEX und Fördervolumen:** Größere Projekte (höheres CAPEX) ermöglichen oft höhere Förderung, aber auch komplexere Risiken

- **Ölpreis und CAPEX:** Hochpreisphasen treiben die Infrastrukturkosten (Bohrschiffe, Plattformen) nach oben

Erweiterungsmöglichkeit: Kopula-basierte (*Copula*) Abhängigkeitsstrukturen können Korrelationen zwischen den Inputvariablen modellieren, ohne die marginalen Verteilungen zu verändern.

5.3 Fehlende Ex-post-Einflüsse und Realoptionen

Wie in Abschnitt 2.2 dargelegt, modellieren wir eine Fire-and-Forget-Investition. In der Realität haben Manager die Möglichkeit:

- **Abbruchoption (*Abandon Option*):** Das Projekt bei drohendem Verlust vorzeitig zu stoppen
- **Erweiterungsoption (*Expand Option*):** Bei überaus günstiger Entwicklung zusätzlich zu investieren
- **Verzögerungsoption (*Delay Option*):** Den Investitionszeitpunkt zu verschieben, bis mehr Informationen vorliegen

Diese Realoptionen haben einen positiven Wert, der in unserem Modell nicht berücksichtigt wird. Unser ROI-Modell stellt somit eine **konservative Untergrenze** des Projektwerts dar.

5.4 Statische Parameter

Das Modell verwendet feste Verteilungsparameter. In der Praxis könnten sich diese Parameter über die Projektdauer ändern — insbesondere der Ölpreis zeigt empirisch ein *Mean-Reverting*-Verhalten, bei dem Preise langfristig zu einem Gleichgewichtsniveau zurückkehren. **Al-Harthy [5]** vergleicht verschiedene stochastische Ölpreismodelle (GBM, Mean-Reverting, Jump-Diffusion) und zeigt, dass die Modellwahl signifikanten Einfluss auf die Investitionsbewertung hat. Ein dynamisches Modell mit zeitabhängigen Parametern und Mean-Reversion wäre eine sinnvolle Erweiterung.

5.5 Single-Project-Perspektive

Die Simulation betrachtet ein einzelnes Projekt isoliert. In einem Portfolio-Kontext können Diversifikationseffekte auftreten: Die Korrelation zwischen verschiedenen Projekten reduziert das Gesamtrisiko des Portfolios. Eine Portfolioperspektive wäre ein nächster logischer Schritt.

6 Fazit

6.1 Zusammenfassung

Die Monte-Carlo-Simulation bietet einen signifikanten Mehrwert gegenüber deterministischen Investitionsrechnungen in der Ölindustrie:

1. **Von Einzelpunkt zu Verteilung:** Statt einer einzelnen ROI-Zahl erhalten Entscheidungsträger eine vollständige Risikoverteilung, die die wesentliche Information enthält: **Wie wahrscheinlich ist ein Verlust?**
2. **Wissenschaftlich fundierte Verteilungswahl:** Die Kombination aus Dreiecks-/PERT-Verteilungen (für Expertenschätzungen) und Lognormalverteilung (für Rohstoffpreise) ist datengerecht und theoriekonform.
3. **Praktische Entscheidungshilfe:** Die Kennzahlen Value at Risk (VaR) und Probability of Loss ($P(\text{ROI} < 0)$) sind direkt entscheidungsrelevant und können in Investitionskomitees kommuniziert werden.
4. **Identifikation von Risikotreibern:** Die Sensitivitätsanalyse zeigt, dass der Ölpreis den größten Beitrag zur ROI-Varianz leistet — eine Erkenntnis, die für Hedging-Strategien und Vertragsstrukturen direkt relevant ist.

6.2 Ausblick

Folgende Erweiterungen werden für die nächste Iteration empfohlen:

- **Korrelationsmodellierung** mittels Copulas zur Erfassung von Abhängigkeiten
- **Realoptionsansatz** zur Bewertung von Management-Flexibilität
- **Zeitabhängige Parameter** für dynamische Ölpreismodelle (Mean-Reversion)
- **Portfolio-Simulation** zur Quantifizierung von Diversifikationseffekten
- **Bayesian Updating** zur Integration neuer Informationen im Projektverlauf

Literatur

- [1] Newendorp, P. D. & Schuyler, J. R. (2000). *Decision Analysis for Petroleum Exploration*. 2. Auflage. Planning Press.
- [2] Rose, P. R. (2001). *Risk Analysis and Management of Petroleum Exploration Ventures*. AAPG Methods in Exploration, No. 12.
- [3] Brennan, M. J. & Schwartz, E. S. (1985). Evaluating Natural Resource Investments. *The Journal of Business*, 58(2), 135–157.
- [4] Al-Harthy, M. H. (2005). On the Validity of the Geometric Brownian Motion Assumption. *The Engineering Economist*, 50(2), 159–176. DOI: 10.1080/00137910590949904.
- [5] Al-Harthy, M. H. (2007). Stochastic Oil Price Models: Comparison and Impact. *The Engineering Economist*, 52(3), 269–284. DOI: 10.1080/00137910701633512.
- [6] SPE 35990 (1996). Probabilistic Drilling-Cost Estimating. *Society of Petroleum Engineers*.

- [7] SPE 52949 (1999). Comparing Three Methods for Evaluating Oil Projects: Option Pricing, Decision Trees, and Monte Carlo Simulations. *Society of Petroleum Engineers*.
- [8] Glasserman, P. (2004). *Monte Carlo Methods in Financial Engineering*. Springer.
- [9] Damodaran, A. (2012). *Investment Valuation*. Wiley Finance.
- [10] Organization of the Petroleum Exporting Countries (OPEC). (2026). *OPEC Basket Price*. Online verfügbar unter: <https://www.opec.org/opec-basket-price.html> (abgerufen am 29.04.2026).
- [11] Hertz, D. B. (1964). Risk Analysis in Capital Investment. *Harvard Business Review*, 42(1), 95–106.
- [12] Vose, D. (2008). *Risk Analysis: A Quantitative Guide*. Wiley.
- [13] Ganat, T. A. O. (2020). *Technical Guidance for Petroleum Exploration and Production Plans*. Springer, Cham.

ISBN 978-3-030-45249-0
- [14] Weber, J. und Schäffer, U. (2016). *Einführung in das Controlling* (15. Aufl.). Schäffer-Poeschel.
- [15] Trigeorgis, L. (1996). *Real Options: Managerial Flexibility and Strategy in Resource Investment*. MIT Press.
- [16] Mun, J. (2006). *Real Options Analysis: Tools and Techniques*. Wiley Finance.
- [17] Leonteq Securities AG. (2023). *Leonteq Brent Crude Oil Futures Total Return Index (LEONCOTT Index)*. Online verfügbar unter: <https://indices.leonteq.com/index-details/LEONCOTT%20Index> (abgerufen am 29.04.2026).